




北京理工大学  
Beijing Institute of Technology

# 本科实验报告

实验名称： 基于 LMS 和 RLS 的滤波器的实现与分析

|        |            |       |  |
|--------|------------|-------|--|
| 课程名称：  | 自适应信号处理    | 实验时间： | 2019.4.25  |
| 任课教师：  | 许文龙        | 实验地点： | 图书馆  |
| 实验教师：  | 许文龙        | 实验类型： | <input type="checkbox"/> 原理验证<br><input checked="" type="checkbox"/> 综合设计<br><input type="checkbox"/> 自主创新 |
| 学生姓名：  | 施念         |       |  |
| 学号/班级： | 1120161302 | 组 号：  |  |
| 学 院：   | 信息与电子学院    | 同组搭档： |  |
| 专 业：   | 电子信息工程     | 成 绩：  |  |



信息与电子学院

SCHOOL OF INFORMATION AND ELECTRONICS

# 基于 LMS 和 RLS 的滤波器的实现与分析

|                         |   |
|-------------------------|---|
| 一 实验目的.....             | 1 |
| 二 实验原理.....             | 1 |
| 1. LMS 算法 .....         | 1 |
| (1) LMS 算法 .....        | 1 |
| (2) NLMS 算法 .....       | 1 |
| (3) LMS-Newton 算法 ..... | 1 |
| 2. RLS 算法 .....         | 2 |
| 三 实验内容.....             | 3 |
| 1. 基于 LMS 的自适应滤波器 ..... | 3 |
| (1) 基本框架说明.....         | 3 |
| (2) LMS 滤波器 .....       | 3 |
| (3) NLMS 滤波器 .....      | 4 |
| (4) LMS-Newton 算法 ..... | 6 |
| 2. 基于 RLS 的自适应滤波器 ..... | 7 |
| (1) RLS 常规算法 .....      | 7 |
| 四 实验总结.....             | 8 |

## 一 实验目的

1. 熟悉并了解各种算法的原理、含义及推导过程。
2. 掌握各种算法的编程方法，通过仿真实现各种算法。
3. 观察仿真结果，分析不同算法之间的联系与差异。

## 二 实验原理

### 1. LMS 算法

#### (1) LMS 算法

最小均方算法（LMS）是一种搜索算法，其通过对目标函数的调整，简化了对梯度向量的计算。特点是计算复杂度低、平稳环境下易于收敛、能无偏收敛到维纳解、利用有限精度算法实现稳定性。

其系数更新方程为：

$$\mathbf{w}(k+1) = \mathbf{w}(k) + 2\mu e(k)\mathbf{x}(k)$$

#### (2) NLMS 算法

归一化的 LMS 算法（NLMS）采用可变收敛因子（步长） $\mu_k$  的思想，在保证不利用相关矩阵的估计值的前提下提高收敛速度。

其系数更新方程为：

$$\mathbf{w}(k+1) = \mathbf{w}(k) + 2\mu_k e(k)\mathbf{x}(k) = \mathbf{w}(k) + \Delta\tilde{\mathbf{w}}(k)$$

取

$$\mu_k = \frac{\mu_n}{\gamma + \mathbf{x}^T(k)\mathbf{x}(k)}$$

其中  $\gamma$  作用是为了避免  $\mathbf{x}^T(k)\mathbf{x}(k)$  很小时出现步长很大的情况，同时，为了控制失调量，需要引入一个固定收敛因子  $\mu_n$ 。

#### (3) LMS-Newton 算法

当输入信号相关性强时，收敛速度慢，LMS-Newton 算法通过对输入信号二阶统计量的估计，提高收敛速度，但也增加计算复杂度。其实质是 Karhunen-Loeve Transform（KL，卡亨南-洛伊夫变换）的最陡下降法。

LMS-Newton 算法的系数更新方程为：

$$\mathbf{w}(k+1) = \mathbf{w}(k) - \frac{1}{2} \mathbf{R}^{-1} \mathbf{g}_w$$

但实际上只能得到  $\mathbf{R}^{-1}$  的估计值，采用加权求和的方法得到  $\hat{\mathbf{R}}(k)$ ，即

$$\begin{aligned} \hat{\mathbf{R}}(k) &= \alpha \mathbf{X}(k) \mathbf{X}^T(k) + (1-\alpha) \hat{\mathbf{R}}(k-1) \\ &= \alpha \mathbf{X}(k) \mathbf{X}^T(k) + \alpha \sum_{i=0}^{k-1} (1-\alpha)^{k-1-i} \mathbf{X}(i) \mathbf{X}^T(i) \end{aligned}$$

其中因子  $\alpha$  用来平衡当前和过去的输入信号，通常取  $0 < \alpha \leq 0.1$ 。

通过矩阵求逆引理可得

$$\hat{\mathbf{R}}^{-1}(k) = \frac{1}{1-\alpha} \left[ \hat{\mathbf{R}}^{-1}(k-1) - \frac{\hat{\mathbf{R}}^{-1}(k-1) \mathbf{X}(k) \mathbf{X}^T(k) \hat{\mathbf{R}}^{-1}(k-1)}{\frac{1-\alpha}{\alpha} + \mathbf{X}^T(k) \hat{\mathbf{R}}^{-1}(k-1) \mathbf{X}(k)} \right]$$

## 2. RLS 算法

最小二乘算法（RLS）采用递归形式，旨在使期望信号与滤波器输出信号之差的平方和达到最小。即使输入信号相关矩阵的特征值扩展比较大，RLS 算法也能实现快速收敛，但是同时需要以增加计算复杂度和存在稳定性为代价。

对于 RLS，其目标函数是确定性的，为

$$\begin{aligned} \xi^d(k) &= \sum_{i=0}^k \lambda^{k-i} \varepsilon(i)^2 \\ &= \sum_{i=0}^k \lambda^{k-i} [d(i) - \mathbf{x}^T(i) \mathbf{w}(k)]^2 \end{aligned}$$

其中  $\varepsilon(i)$  为后验误差（ $e(i)$  为先验误差）， $\lambda$  为遗忘因子（ $0 \ll \lambda \leq 1$ ）。

$\xi^d(k)$  对  $\mathbf{w}(k)$  求偏导，令其结果为 0 可得 RLS 算法的最优向量，即

$$\begin{aligned} \mathbf{w}(k) &= \left[ \sum_{i=0}^k \lambda^{k-i} \mathbf{x}(i) \mathbf{x}^T(i) \right]^{-1} \sum_{i=0}^k \lambda^{k-i} \mathbf{x}(i) d(i) \\ &= \mathbf{R}_D^{-1}(k) \mathbf{p}_D(k) \end{aligned}$$

其中  $\mathbf{R}_D(k)$  是输入信号的确定性相关矩阵， $\mathbf{p}_D(k)$  为输入信号与期望信号的确定性互相关向量。并且  $\mathbf{R}_D^{-1}(k)$  采用 LMS-Newton 算法中的求逆引理进行求解。

上式经过变换，采用先验误差，可得到另一种常规的 RLS 算法，其系数更新方程为：

$$w(k) = w(k-1) + e(k)S_D(k)x(k)$$

### 三 实验内容

#### 1. 基于 LMS 的自适应滤波器

##### (1) 基本框架说明

##### a. 滤波器框图

下图为经典滤波器框图，本实验中主要改变的是不同的自适应算法（LMS 算法及其变形、RLS 算法）。




图 一 经典滤波器框图

##### b. 算法实现

如下图所示，通常采用延迟线的方法实现 LMS 算法。本实验中为了更好的绘制 MSE 曲面上的收敛路径，采用一阶 FIR 自适应滤波器。

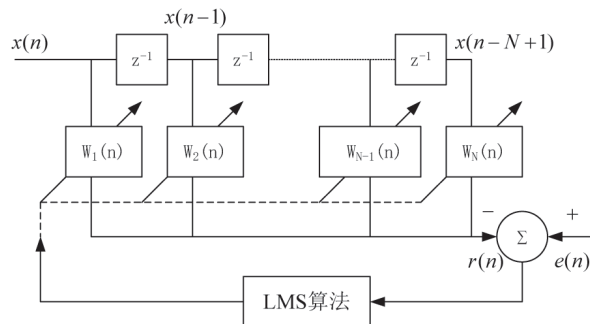


图 二 LMS 自适应滤波器

##### (2) LMS 滤波器


##### a. 初始化

假设滤波器为基于 LMS 的一阶自适应 FIR 滤波器，以系统辨识为例。取滤波器的最优系数为  $\begin{bmatrix} 0.5 \\ -0.5 \end{bmatrix}$ ，步长为 0.1，观察噪声的方差（能量）为 0.04。观察迭代 500 次的 MSE 和系数收敛路径。

### b. 说明

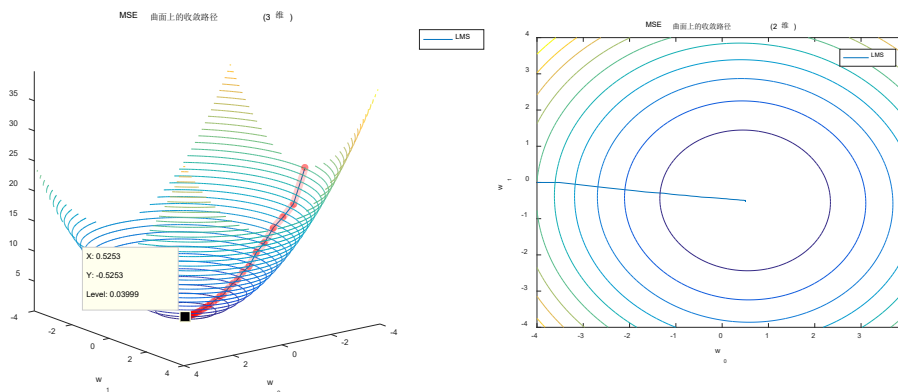
为了使结果更加准确，每次的系数迭代都进行 1000 次，取 1000 次的系数均值作为迭代后的系数。

### c. 结果与分析



图三 LMS 算法的 MSE 学习曲线

从图三我们可以看出，在迭代次数到 50 次时，系数收敛，达到最优系数。



图四 LMS 算法下系数的收敛路径

从图四（a）可以看出，随着系数不断靠近最优系数，MSE 越来越小，到靠近最优系数  $\begin{bmatrix} 0.5 \\ -0.5 \end{bmatrix}$  时， $\xi = 0.03999$  ( $w = \begin{bmatrix} 0.5253 \\ -0.5253 \end{bmatrix}$ )，接近理论的  $\xi_{min}(\sigma_d^2)$ ，即 0.04。图四（b）是收敛路径在 x-y 平面上的投影。

### （3）NLMS 滤波器

### a. 初始化

对于 NLMS 来说，其可变步长  $\mu_k$  由  $\gamma$ 、 $\mu_n$  以及  $k$  时刻的输入信号  $x^T(k)x(k)$  决定。初始化  $\gamma$  为一很小的常数 ( $1e-12$ )， $\mu_n$  取 0.1，其他的与上述 LMS 算法的初始化相同。

### b. 说明

为了观察 NLMS 收敛路径“先趋向于主轴再靠近最优系数”的特性，选择  $\begin{bmatrix} -4 \\ -4 \end{bmatrix}$  作为起点。

### c. 结果与分析




图 五 NLMS 算法的 MSE 学习曲线

从图五我们可以看出，随着迭代次数的不断增加，在大约 100 次时，系数收敛，近似达到最优系数。




图 六 NLMS 算法下系数的收敛路径

从图六我们可以看出，该算法路径先靠近主轴，再沿着主轴方向收敛到最优系数。

在实验中，我发现：如图七所示，在其他条件相同的情况下，NLMS 算法到达最优系数所需迭代次数是 LMS 算法的两倍。




图 七 MSE 学习曲线对比

通过分析代码和洗漱更新方程可知，在输入信号（`sign(randn(N,1))`）瞬时功率（ $x^T(k)x(k)$ ）一定时（本实验为 2），若  $\gamma$  很小，则  $\mu_k = \frac{\mu_n}{2}$ ，收敛步长为 LMS 的一半，自然迭代次数大约是 LMS 的两倍。由此可知，NLMS 算法并不适用于所有信号，当输入信号  $x^T(k)x(k)$  为一定值时，NLMS 退化为 LMS。

#### （4）LMS-Newton 算法

##### a. 初始化


对于 LMS-Newton 算法， $\hat{R}^{-1}$  初始化为  $\delta I$ ， $\delta$  为一很小的正常数（取 0.1），平衡当前与过去的因子  $\alpha$  取 0.05，在进行系数更新之前要计算  $\hat{R}^{-1}$  的值。其他参数的初始化与 LMS 算法相同

##### b. 说明

当 RLS 算法选取的遗忘因子  $\gamma$  满足  $2\mu = \alpha = 1 - \gamma$ ，则对于 LMS-Newton 算法，其在此时与 RLS 算法在数学上是等价的。


##### c. 结果与分析





图八 LMS-Newton 算法的 MSE 学习曲线

从图八可以看出，在接近 100 次迭代后，系数收敛，近似达到最优系数。



图九 MSE 曲面上的系数收敛路径

从图九可以看出，LMS-Newton 算法直接趋近于极小值点。其区别于 LMS 算法，不需要接近小特征值的主轴（特征向量），能够以更加直接的路径收敛到 MSE 曲面的极小值点。

## 2. 基于 RLS 的自适应滤波器

### (1) RLS 常规算法

#### a. 初始化

假设滤波器为基于 LMS 的四阶自适应 FIR 滤波器，以系统辨识为例。取滤波器的最优系数为  $[1.6 - j0.3, -0.6 + j1.25, 0.8 - j0.1, 0.75 + j0.3, 1.2 + j0.5]^T$ ，观察噪声的方差（能量）为 0.04。遗忘因子  $\lambda$  取 0.9，初始化  $S_D = \delta I$ （ $\delta$  取 0.1），观察迭代 500 次的 MSE 以及前两次的系数收敛曲线。

#### b. 说明

为了使结果更加准确，每次的系数迭代都进行 1000 次，取 1000 次的系数均值作为迭代后的系数。

### c. 结果与分析




图 十 RLS 算法的 MSE 学习曲线

从图十可以看出，在进行 50 次迭代后，系数逐渐收敛，在 80 次近似达到最优系数  $w_o$ 。




图 十一 某个系数的学习曲线

从图十一可以看出，对于第 1 个系数和第 4 个系数，在迭代次数达到 75 次左右，二者均收敛到最优系数（ $1.6 - j0.3$  和  $0.75 + j0.3$ ）。

## 四 实验总结

本次实验，第一方面加深了我对 LMS 算法和 RLS 算法以及一些基于二者的算法有了更深的印象和理解，更加熟悉了公式的推倒以及各个算法的内涵。

以 LMS 算法为例，LMS-Newton 算法其性能与输入信号相关矩阵的特征值扩展无关，其与 RLS 算法相近（当 RLS 算法选取的遗忘因子  $\gamma$  满足  $2\mu = \alpha = 1 - \gamma$ ，LMS-Newton 算法在此时与 RLS 算法在数学上是等价的），其能降低计算复杂度（主要针对  $\hat{R}^{-1}$ ）。对于归一化的 LMS 算法（NLMS），其核心内涵是可变的步长，当将其步长进一步扩展，利用最大相关熵（MCC）的思想，可得到基于 MCC 的可变步长自适应滤波器。

通过此次实验，我掌握了 MATLAB 实现自适应滤波器的编程方法，并且学会了如何从多个角度去评价一个算法的好坏。除此之外，这个实验也为我下个实验（LMS 和 RLS 滤波器的应用）提供一定的基础。